



COMILLAS

UNIVERSIDAD PONTIFICIA

ICAI

ICADE

CIHS

Adquisición y visualización de datos

Grado IMAT · Comillas
ICAI

Curso
académico

2026 / 2027

comillas.edu

Proyecto de la Asignatura





Proyecto Colaborativo

¡¡ Somos campeones del Mundo ★★ !!

¡Y el Mundial 2026 no lo vamos a olvidar!

Pero ¿qué ha pasado realmente en este Mundial?

Es hora de analizar los **datos de los partidos, eventos y jugadores sucedidos en este mundial**, y mostrar y explicar visualmente algunas de las conclusiones más interesantes.

El objetivo de este **Proyecto Colaborativo** es realizar un **Análisis Resumen del Mundial 2026**, partiendo de distintos datasets que con información estadística y complementando el análisis con datos obtenidos en la web.

El análisis se materializará **a través de distintos elementos visuales**, en forma de explicaciones mediante gráficos explicativos y con un Cuadro de Mando resumen para cada Selección; **y utilizando las técnicas vistas en clase.**

Estructura del Proyecto Colaborativo

- El Proyecto Colaborativo tendrá **cuatro Bloques** secuenciales. **Cada bloque tendrá una Entrega asociada.**
- Para que el trabajo se considere presentado, **se deben realizar todas las entregas en tiempo.**
- **La calificación del trabajo será única y al final de este.**
- El objetivo y fecha de entrega de cada bloque es el siguiente:

Bloque	Objetivo	Fecha de Entrega	Temario asociado
Bloque 1	Recopilación, limpieza y tratamiento de datasets de trabajo	9 de octubre	Pandas (Tema 3), Limpieza de Datos (Tema 4), Técnicas de Imputación de Datos (Tema 5)
Bloque 2	Elaborar tres tipos de Análisis en forma de gráficos y presentación para analizar los datos recopilados	30 de octubre	Visualización programática (Tema 6), técnicas y conceptos de visualización (Tema 7)
Bloque 3	Crear un Cuadro de Mando con el resumen de la actuación de cada Selección en el Mundial	13 de noviembre	Visualización en herramientas comerciales, cuadros de mando y Power BI (Tema 8)
Bloque 4	Complementar los datasets con información obtenida vía API de jugadores y localización de estadios.	27 de noviembre	Expresiones regulares (Tema 2), extracción y procesamiento de datos vía API (Temas 10 y 11), organización y formatos de datos (Tema 8), repositorios de Git

- En las páginas siguientes se encuentran los Enunciados de cada Bloque.

Trabajo con Repositorio Git

Cada grupo deberá elaborar un **Repositorio Compartido de Git**. En él se centralizarán también todas las entregas y funcionará como **Repositorio de Proyecto**.

Al final del trabajo, durante la entrega del Bloque 4, deberá entregarse al enlace a este repositorio con todo el código y documentación generada.

Se recomienda comenzar a trabajar de manera compartida en este repositorio lo antes posible.

Para trabajar con el repositorio se deberán seguirse las siguientes directrices:

- Debe usarse un repositorio compartido de Git para el proyecto.
- El repositorio debe estar organizado **mediante ramas y deben utilizarse commits para gestionar los cambios**.
- Los miembros de cada equipo deben realizar integración de código a través del repositorio.
- **Debe existir un control de versiones**, y se penalizará no seguir las buenas prácticas de desarrollo colaborativo.

Bloque 1 – Enunciado

Cada grupo dispone de un paquete con varios archivos en formato .csv que deberá revisar y analizar, para extraer de ellos la información necesaria.

Sin embargo, muchos de estos datasets tendrán datos erróneos, información incompleta y valores anómalos que se deberán tratar convenientemente utilizando las técnicas vistas en clase.

Para ello debe crear un script que realice los siguientes pasos:

- 1) La carpeta **datasetsWC26.zip** dispone de varios archivos .csv con distintos datos sobre el Mundial 2026. Utilizando Pandas, impórtelos y realice una exploración inicial de todos ellos para entender su contenido, formato de datos y tamaño.
- 2) Cree tres variables de tipo DataFrame llamadas **partidos**, **eventos** y **jugadores**, en las que almacenará únicamente la información requerida para el análisis posterior.
- 3) Utilizando funciones y métodos de Pandas sobre los datasets originales, añada a los DataFrames **partidos**, **eventos** y **jugadores** las columnas y datos que **se indican en la página siguiente**. **No deben existir columnas adicionales y deben respetarse los nombres y etiquetas** indicados. Además, **los tipos de datos deben estar correctamente aplicados** (fechas, valores enteros, strings...).
- 4) Utilizando las técnicas de clase, lleve a cabo la limpieza de los datasets y realice un tratamiento correcto de los valores duplicados, nulos y anómalos que pudieran contener. Justifique las medidas adoptadas (*Consejo: antes de aplicar las medidas, es conveniente entender bien el contenido de los datasets, con apoyo, si hace falta, a través de algún gráfico de barras, histograma o métodos de análisis como .describe o .info. También es recomendable aplicar estas técnicas una vez seleccionadas únicamente las columnas de interés*).
- 5) Identifique en el dataset **eventos** los valores anómalos que deben excluirse, teniendo en cuenta **los minutos anómalos o incorrectos y la consistencia en los tipos de eventos**. No elimine los registros sin minuto asociado ya que se imputarán más adelante.
- 6) La fecha de los partidos aparece en distintos formatos. Utilizando expresiones regulares, identifique el patrón correspondiente a cada registro y reconstruya una columna **“fecha_partido”** homogénea con el día mes y año.
- 7) Observará que hay datos faltantes en algunas filas. Complete la información faltante utilizando las siguientes Técnicas de Imputación:
 - **Valor_mercado**: complete los datos faltantes utilizando **Imputación por la Media** de todos los jugadores **de la misma Selección** del jugador a imputar.
 - **Calificacion_media**: complete los datos faltantes con **Imputación por Regresión** basada en la correlación con las estadísticas de goles, asistencias, tarjetas amarillas y rojas, paradas o goles concedidos (*Consejo: distinga el caso de porteros y otras posiciones*)
 - **Minuto_evento**: complete los datos faltantes utilizando **Imputación por Interpolación** considerando los eventos previos y posteriores del mismo partido.
- 8) Finalmente, exporte los tres DataFrames a tres documentos Excel: **partidosWC26.xlsx**, **eventosWC26.xlsx** y **jugadoresWC2026.xlsx**

Bloque 1 – Resultado esperado

Los datasets que se generen al final del Bloque 1 deben contener **únicamente** la siguiente información.

Toda la información adicional que esté en los datos originales debe ser eliminada.

partidos: resumen de todos los partidos del Mundial.

Índice

- index_partido (1, 2, 3...)

Columnas (13)

- fecha_partido (dd/mmmm/aa)
- ronda (grupos, cuartos, semifinal)
- estadio (nombre del estadio)
- ciudad_partido
- pais_partido
- seleccion_local (e.g. Alemania)
- seleccion_visitante
- marcador_local (nº de goles anotados)
- marcador_visitante
- prorroga (variable SI o NO)
- penalty_local (0 si no aplica)
- penalty_visitante
- arbitro_partido (nombre del arbitro)

jugadores: datos de todos los jugadores del Mundial y estadísticas en el torneo-

Índice

- nombre_jugador

Columnas (15)

- seleccion_nacional (e.g. Alemania)
- club_jugador (e.g. Real Madrid)
- partidos_seleccion (numérico)
- posicion (portero, defensa, delantero...)
- valor_mercado (e.g. 100 M€)
- partidos_jugados (numérico)
- minutos_jugados (numérico)
- goles (numérico)
- asistencias (numérico)
- tiros (numérico)
- tarjetas_amarillas (numérico)
- tarjetas_rojas (numérico)
- paradas (numérico)
- goles_concedidos (numérico)
- calificacion_media (del 0 al 10)

eventos: resumen de los eventos sucedidos en cada partido del Mundial.

Cada evento puede ser un gol, una asistencia, una tarjeta (amarilla o roja), un penalty marcado o fallado o una revisión del VAR.

Índice

- index_evento (1, 2, 3...)

Columnas (5)

- minuto_evento
- index_partido (asociado al evento)
- nombre_jugador (asociado al evento)
- tipo_evento (gol, asistencia...)
- seleccion_evento (asociado al jugador)

Bloque 2 – Enunciado

Debe realizar **tres análisis diferentes sobre los datos generados en el Bloque 1**. Para ello, realice los siguientes ejercicios:

ANÁLISIS 1. Ventanas de Partidos. Se quiere evaluar en qué minutos se deciden los partidos y dónde se concentran los eventos más relevantes. Para ello genere las siguientes visualizaciones [utilizando las librerías Plotly y Streamlit](#):

- 1) **Cree un gráfico de barras que muestre, para un partido a escoger, los eventos que suceden en el mismo.** En el eje horizontal se representa el tiempo de partido, y en las barras verticales el tipo de evento. Debe poder visualizarse el jugador y el minuto asociado, y una leyenda según tipo de evento.
- 2) **Cree un mapa de calor que muestre la densidad de eventos (goles, tarjetas...) a lo largo del tiempo de partido.** Debe poder filtrarse por tipo de evento y ronda del partido (octavos, semifinales...). ¿En qué intervalo se producen más goles? ¿Son las segundas partes más “entretenidas” que las primeras? ¿Y las prórrogas?
- 3) **Cree un gráfico circular (o similar) que muestre, para una Selección a escoger, la distribución de todos los eventos asociados en el Mundial** (goles, asistencias, tarjetas...). Deben visualizarse claramente los que han sido a favor como en contra (e.g. 3 goles a favor, 7 amarillas en contra, etc.).

ANÁLISIS 2. Rendimiento de Jugadores Clave. Se quiere evaluar qué jugadores han dado un mejor rendimiento en el Mundial y si realmente las grandes estrellas han cumplido las expectativas o han decepcionado. Para ello genere las siguientes visualizaciones [utilizando las librerías Plotly y Streamlit](#):

- 4) **Cree un gráfico de dispersión que enfrente “Valor de Mercado” vs “Calificación Media”** para todos aquellos jugadores que hayan jugado al menos 180 minutos en el Mundial. Debe incorporarse un selector que permita filtrar por Selección, Partidos Jugados o Posición. ¿Qué conclusiones pueden obtenerse? ¿Qué correlación existe entre ambas variables?
- 5) **Defina las siguientes métricas:** *goles/minuto, goles+asistencias/minuto, asistencias/minuto, goles_concedidos/minuto, tarjetas_amarillas/minuto y tarjetas_rojas/minuto*; y una **métrica agregada** que pondere todas ellas. **Cree un gráfico para visualizar en barras el top15 de mejores jugadores en una de las métricas a escoger, junto a su ranking en valor de mercado** (e.g. 3º, 148º...). ¿Coinciden los jugadores más valiosos con los que mejor rendimiento han dado?
- 6) **Cree un gráfico de burbujas que relacione Minutos Jugados, Calificación Media y Valor de Mercado**, con posibilidad de visualización por Selección y Posición. **Indique en un color específico de burbuja los jugadores que han marcado.** ¿Se observan casos de sobre rendimiento o infrarrendimiento de jugadores?



ANÁLISIS 3. Impacto Arbitral. Se quiere analizar si existen patrones diferenciados en el criterio arbitral a lo largo del Mundial. Para ello genere las siguientes visualizaciones [utilizando las librerías Plotly y Streamlit](#):

- 7) **Cree un diagrama de caja (box plot) que muestre la distribución del número de tarjetas por partido, agrupado por ronda del Mundial (grupos, octavos...) y de manera que en los puntos se pueda identificar el partido asociado.** ¿Se puede observar algún cambio en el criterio arbitral al avanzar la competición? ¿?
- 8) **Defina un “Índice de Intervención Arbitral”** (tarjeta amarilla=1 punto; tarjeta roja=3 puntos, VAR Review=1 punto, Gol=0.2 puntos). **Represente para cada árbitro (eje Y) el valor en sus partidos arbitrados (eje X) y la media del índice.** ¿Qué conclusiones puede obtener? **Permita filtrar por Ronda y Selección.** Para cada Selección, ¿qué árbitros han sido menos severos de todos los que ha disputado y cuáles menos? ¿Hay coincidencias en los árbitros de dichos partidos?



Bloque 2 – Guía de Gráficos a utilizar

A modo de **ejemplo** se muestra a continuación qué tipos de gráficos deben elaborarse en cada análisis.



ANÁLISIS 1



ANÁLISIS 2



ANÁLISIS 3



Bloque 3 – Enunciado

El objetivo del **Bloque 3** es crear un Cuadro de Mando que permita analizar la información de cada Selección, utilizando PowerBI.

Para ello, deben realizarse los siguientes ejercicios.

- 1) Se trabajará con los archivos **partidosWC26.xlsx**, **eventosWC26.xlsx** y **jugadoresWC2026.xlsx** generados en el Bloque 1. No es necesario utilizar ningún resultado obtenido en el Bloque 2. Estos archivos pueden adaptarse y combinarse para la resolución.
- 2) **Definir el modelo de datos en Power BI** estableciendo las relaciones entre los DataFrames.
- 3) **Desarrollar un Cuadro de Mando en PowerBI** que, como mínimo, contenga los siguientes elementos gráficos:
 - Un **Selector** con la capacidad de escoger y mostrar cada una de las 48 Selecciones del Mundial.
 - Un elemento visual llamado **Plantilla**, que muestre el listado de jugadores de la Selección, indicando posición, partidos jugados, goles, asistencias (en jugadores de campo) y goles encajados (porteros).
 - Un elemento visual llamado **Resumen Estadístico**, que contenga la siguiente información:
 - Un **gráfico circular** que muestre Victorias, Empates y Derrotas
 - Un **gráfico circular** que muestre Goles Marcados y Goles Encajados
 - Un **marcador con la Calificación Media** de los jugadores.
 - Un elemento visual horizontal llamado **Actuación Partidos** que muestre todos los elementos
 - Un **elemento visual adicional a elección del grupo**.
- 4) **Los siguientes aspectos deberán ser tenidos en cuenta y se valorarán positivamente en la nota final:**
 - Limpieza, formato, claridad y “look&feel” general del Cuadro de Mando.
 - Calidad en la representación de la información.
 - Capacidad de reutilización del Cuadro de Mando con otras fuentes de datos (e.g. los mismos archivos referentes a otra competición).

Bloque 3 – Resultado esperado

A modo de ejemplo se muestra un **ejemplo** de la disposición de los distintos elementos en el Cuadro de Mando.



Bloque 4 – Enunciado

Todo el proyecto deberá centralizarse en un repositorio centralizado de Git, y el trabajo deberá ser colaborativo en él para cada grupo.

- 1) Utilice Git y un repositorio compartido para gestionar de forma colaborativa el desarrollo del trabajo realizado en los apartados anteriores. Se deberán utilizar ramas y *commits* para organizar los cambios realizados por los distintos integrantes del equipo y facilitar la integración del Código (siga los detalles indicados en la página 4)

Adicionalmente, la página web <https://www.api-football.com/> contiene multitud de datos de fútbol (jugadores, partidos, equipos...) que puede explotarse vía API. Adicionalmente, la web <https://www.openstreetmap.org/> es muy utilizada para la extracción de datos geográficos.

Utilizando los datos de <https://www.api-football.com/>, realice los siguientes ejercicios:

- 2) **Analice la documentación de la API para poder extraer esta información (ver detalle más adelante).**
- 3) **Cree un script ejecutable en Python que**, partiendo de un fichero Excel con nombres de jugadores, **realice una consulta a la API** indicada para extraer la fecha de nacimiento, la altura y el peso de cada uno. Esta información debe almacenarse en el mismo DataFrame original como las columnas **fecha_nacimiento**, **altura_jugador** y **peso_jugador**. Si algún dato no estuviera disponible, indíquelo.
- 4) Algunos estudios sugieren que existe relación entre el éxito deportivo y la fecha de nacimiento, de manera que el primero es mayor para los. **Analice la distribución de la fecha de nacimiento de todos los jugadores del Mundial 2026 y muestre la información en forma de gráfico utilizando el formato que considere más adecuado.** ¿Qué conclusiones puede obtener?

Utilizando los datos de <https://www.openstreetmap.org/>, realice los siguientes ejercicios:

- 5) **Analice la documentación de la API para poder extraer esta información (ver detalle más adelante).**
- 6) **Cree un script ejecutable en Python que**, partiendo de un fichero Excel con nombres de estadios de fútbol, **realice una consulta a la API para extraer su posición geográfica en forma de latitud y longitud.** Utilícelo para extraer dicha información para los estadios del Mundial 2026.
- 7) **Utilizando Streamlit y Plotly, cree un dashboard interactivo** en el que se muestre un mapa de Norteamérica y aparezca cada estadio representado con una burbuja en su localización, **en el que el tamaño y color de la burbuja dependa del número de partidos jugados y goles marcados en él.** Debe incorporar un selector que permita escoger la ronda (Fase de Grupos, 16avos, etc.).

Bloque 4 – API de api-football.com


- Para extraer los datos de jugadores vía API se utilizará la web: <https://www.api-football.com/>



- Es necesario registrarse únicamente con una cuenta de correo.
- En el menú principal <https://dashboard.api-football.com/#> se pueden consultar lo siguiente:
 - **Account > My Access:** permite visualizar la API-KEY del usuario.
 - **APIs > Football > Documentation:** da acceso a la documentación de la API donde se indica cómo realizar las consultas y qué tipo de datos se pueden extraer. También se puede consultar en <https://www.api-football.com/documentation-v3>.
 - **Tutorials** > Incluye manuales y guías de uso para extraer ciertos tipos de datos relevantes.
- **¡¡IMPORTANTE!!** El plan gratuito da acceso a la información requerida, con un límite de 100 llamadas a la API al día. Sin embargo, es posible que el número de jugadores de los que tenga que extraer la información sea mayor. **Por tanto, cada grupo debe eficientar el código con el fin de maximizar el número de datos extraídos en cada consulta.**

Bloque 4 – API de [openstreetmap.org](https://www.openstreetmap.org)

- Para extraer las coordenadas geográficas de los estadios se usará <https://www.openstreetmap.org>
- Para realizar consultas a la API no se requiere ni usuario ni clave de acceso.
- **Actualmente, la versión de la API en curso es la v0.6.** La documentación para su uso puede consultarse en la siguiente URL https://wiki.openstreetmap.org/wiki/API_v0.6.



Instrucciones de entrega

- Cada grupo realizará 4 entregas. **Es suficiente que un único alumno por grupo realice la entrega.**
- **Las entregas no se evaluarán de manera individual**, pero deberán realizarse todas ellas para que el Proyecto sea calificado.
- **Todas las entregas se harán a través de Moodle.** **No se admitirán entregas por correo electrónico.**
- **Para cada Bloque, cada grupo entregará un único archivo .zip con el siguiente contenido:**

Bloque	Contenido del fichero .zip
Bloque 1	• <u>1 archivo .py (script de Python, no se aceptará Notebook)</u> con el código ejecutable para el tratamiento de los datasets, debidamente formulado y comentado. • <u>3 archivos Excel</u> con los resultados finales: <i>partidosWC26.xlsx</i>, <i>eventosWC26.xlsx</i> y <i>jugadoresWC2026.xlsx</i>
Bloque 2	• <u>1 archivo .py (script de Python, no se aceptará Notebook)</u> con el código ejecutable para la resolución de los ejercicios del Bloque, debidamente separado por secciones, formulado y comentado. • <u>1 archivo PowerPoint</u> dividido en tres secciones con los gráficos, resultados y conclusiones de cada uno de los 3 análisis realizados. Se valorará el formato, la claridad y la precisión de las conclusiones obtenidas.
Bloque 3	• <u>1 archivo .pbix (formato de PowerBI)</u> con el Cuadro Mando elaborado. • <u>3 o más archivos Excel</u> que se hayan utilizado como fuente para el modelo de datos
Bloque 4	• <u>1 archivo .py (script de Python, no se aceptará Notebook)</u> ejecutable que extraiga y procese la información requerida de las APIs y genere las visualizaciones requeridas. El archivo debe estar debidamente formulado y comentado. • <u>1 Enlace al repositorio Compartido Git</u> utilizado para desarrollar el Proyecto, con el código desarrollado e incluyendo commits, ramas e integración de los cambios realizados por los integrantes del equipo, así como Documentación de apoyo (presentaciones, explicaciones y comentarios). Con él debe poder ejecutarse la totalidad de los scripts desarrollados a lo largo del proyecto.

